

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ - ĐHQGHN
VIỆN TRÍ TUỆ NHÂN TẠO



BÁO CÁO MÔN HỌC
HỌC SÂU

ĐỀ TÀI:

XÂY DỰNG HỆ THỐNG DỊCH MÁY
TRANSFORMER TỪ ĐẦU:
DỊCH ANH - VIỆT CHO Y TẾ

Nhóm sinh viên thực hiện: Nguyễn Phương Nam - 23020406
Nguyễn Trọng Hồng Phúc - 23020410
Nguyễn Đình Quyền - 23020422
Trần Doãn Thắng - 23020438

Giảng viên hướng dẫn: PGS.TS. Nguyễn Việt Hà
ThS. Nguyễn Thị Thùy Linh

HÀ NỘI, 2025

Mục lục

1	Giới Thiệu Dự Án	4
1.1	Đặt Vấn Đề Nghiên Cứu	4
1.2	Mục Tiêu Nghiên Cứu	4
2	Cơ Sở Lý Thuyết và Công Nghệ	5
2.1	Dịch máy Nơ-ron (Neural Machine Translation - NMT)	5
2.2	Kiến trúc Transformer	5
2.2.1	Cơ chế Self-Attention	6
2.2.2	Multi-Head Attention	6
2.2.3	Positional Encoding	6
2.3	Kỹ thuật Tinh chỉnh (Fine-tuning)	6
2.4	Các chỉ số đánh giá	6
2.4.1	BLEU Score (Bilingual Evaluation Understudy)	7
2.4.2	Perplexity (PPL)	7
3	Phân tích và Thiết kế Hệ thống	8
3.1	Bộ Dữ liệu và Tiền xử lý	8
3.1.1	Nguồn dữ liệu	8
3.1.2	Quy trình Làm sạch và Chuẩn hóa	9
3.1.3	Thống kê Dữ liệu sau xử lý	9
3.2	Thiết kế Mô hình From Scratch	9
4	Xây Dựng và Huấn Luyện Hệ Thống	10
4.1	Môi trường và Công nghệ	10
4.2	Chiến lược Huấn luyện	10
4.2.1	Giai đoạn 1: Huấn luyện mô hình nền tảng (Baseline Pre-training)	10
4.2.2	Giai đoạn 2: Fine-tuning (Chuyên biệt hóa)	11
4.2.3	Giai đoạn 3: Thực nghiệm so sánh (Benchmark) với các mô hình SOTA	13
4.3	Đoạn mã cốt lõi	14
5	Kết Quả Thực Nghiệm	15
5.1	So sánh Định lượng	15
5.2	Đánh giá Định tính	16
5.2.1	Khả năng thích ứng với thuật ngữ Y khoa	16
5.2.2	Khả năng xử lý câu phức và cấu trúc dài	17
5.2.3	Phân tích lỗi	17

6	Kết luận và Hướng phát triển	18
6.1	Tổng kết các đóng góp chính	18
6.2	Các hạn chế còn tồn tại	19
6.3	Hướng phát triển trong tương lai	19

Danh sách bảng

1	Thống kê bộ dữ liệu Y tế sau khi làm sạch	9
2	Cấu hình siêu tham số của mô hình From Scratch	10
3	Kết quả đánh giá thực nghiệm (BLEU & Perplexity)	16

Danh sách hình vẽ

1	Kiến trúc tổng quan của mô hình Transformer [1]	5
2	Sơ đồ tổng quan quy trình tiền xử lý, huấn luyện và đánh giá mô hình dịch máy Y học	8

1 Giới Thiệu Dự Án

1.1 Đặt Vấn Đề Nghiên Cứu

Trong kỷ nguyên toàn cầu hóa, rào cản ngôn ngữ là một trong những trở ngại lớn nhất trong việc tiếp cận tri thức, đặc biệt là trong lĩnh vực Y học. Các tài liệu y khoa cập nhật nhất, các nghiên cứu lâm sàng và hướng dẫn điều trị chuẩn mực thường được viết bằng tiếng Anh. Tại Việt Nam, nhu cầu dịch thuật tài liệu y tế là rất lớn để phục vụ cho bác sĩ, sinh viên y khoa và cả bệnh nhân.

Tuy nhiên, các công cụ dịch phổ biến hiện nay (như Google Translate) thường hoạt động tốt trên ngôn ngữ đời sống nhưng gặp khó khăn với các thuật ngữ chuyên ngành, ngữ cảnh lâm sàng phức tạp và yêu cầu độ chính xác tuyệt đối. Sai sót trong dịch thuật y tế có thể dẫn đến những hậu quả nghiêm trọng.

Sự phát triển của kiến trúc Transformer [1] đã tạo ra một cuộc cách mạng trong Xử lý ngôn ngữ tự nhiên (NLP). Tuy nhiên, việc huấn luyện các mô hình này đòi hỏi tài nguyên khổng lồ. Câu hỏi đặt ra là: *Liệu một mô hình Transformer được xây dựng từ đầu (From Scratch) với kích thước vừa phải, khi được tinh chỉnh (Fine-tune) trên dữ liệu chuyên biệt, có thể đạt hiệu suất tốt hay không?*

1.2 Mục Tiêu Nghiên Cứu

Dự án này tập trung vào việc xây dựng và so sánh hiệu năng của các hệ thống dịch máy Anh - Việt chuyên ngành Y tế. Các mục tiêu cụ thể bao gồm:

- Xây dựng kiến trúc Transformer từ đầu (không dùng thư viện có sẵn hàm ‘Transformer’ mức cao) để hiểu sâu cơ chế hoạt động.
- Huấn luyện mô hình cơ sở (Baseline) trên dữ liệu phổ thông.
- Thu thập và xử lý bộ dữ liệu song ngữ chuyên ngành Y tế chất lượng cao.
- Thực hiện kỹ thuật Fine-tuning để chuyên biệt hóa mô hình Baseline cho tác vụ y tế.
- Đánh giá và so sánh hiệu quả với các mô hình ngôn ngữ lớn tiên tiến (SOTA) như **VinAI Translate** và **MedCrab** để làm rõ tiềm năng của mô hình tự xây dựng.

2 Cơ Sở Lý Thuyết và Công Nghệ

2.1 Dịch máy Nơ-ron (Neural Machine Translation - NMT)


Dịch máy Nơ-ron là phương pháp sử dụng mạng nơ-ron nhân tạo để dự đoán khả năng xuất hiện của một chuỗi từ trong ngôn ngữ đích dựa trên chuỗi từ ở ngôn ngữ nguồn. Khác với dịch máy thống kê (SMT), NMT xử lý đầu vào và đầu ra dưới dạng các vector liên tục, cho phép mô hình học được sự phụ thuộc ngữ nghĩa phức tạp.

Mô hình NMT thường có cấu trúc **Encoder-Decoder**:

- **Encoder:** Mã hóa câu nguồn thành một vector ngữ cảnh (context vector).
- **Decoder:** Giải mã vector ngữ cảnh để sinh ra câu đích, từ này qua từ khác.

2.2 Kiến trúc Transformer

Transformer là kiến trúc nền tảng cho hầu hết các mô hình ngôn ngữ hiện đại (BERT, GPT, T5). Nó loại bỏ hoàn toàn các mạng hồi quy (RNN/LSTM) và chỉ dựa vào cơ chế Attention.



Hình 1: Kiến trúc tổng quan của mô hình Transformer [1]

2.2.1 Cơ chế Self-Attention

Self-Attention cho phép mô hình xem xét các vị trí khác nhau của chuỗi đầu vào để tính toán biểu diễn cho vị trí hiện tại. Công thức cốt lõi là Scaled Dot-Product Attention:

$$Attention(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (1)$$

Trong đó:

- Q (Query): Truy vấn.
- K (Key): Khóa.
- V (Value): Giá trị.
- d_k : Kích thước của vector key (dùng để chuẩn hóa).

2.2.2 Multi-Head Attention

Thay vì chỉ thực hiện attention một lần, Transformer chạy song song h "heads" attention khác nhau. Điều này cho phép mô hình tập trung vào các không gian biểu diễn khác nhau tại các vị trí khác nhau.

$$MultiHead(Q, K, V) = Concat(head_1, \dots, head_h)W^O \quad (2)$$

2.2.3 Positional Encoding

Vì Transformer không xử lý tuần tự (như RNN), nó cần thông tin về vị trí của từ trong câu. Positional Encoding được cộng vào Embeddings đầu vào:

$$PE_{(pos, 2i)} = \sin(pos/10000^{2i/d_{model}}) \quad (3)$$

$$PE_{(pos, 2i+1)} = \cos(pos/10000^{2i/d_{model}}) \quad (4)$$

2.3 Kỹ thuật Tinh chỉnh (Fine-tuning)

Fine-tuning là quá trình lấy một mô hình đã được huấn luyện trước (Pre-trained) trên tập dữ liệu lớn và tiếp tục huấn luyện nó trên một tập dữ liệu nhỏ hơn, chuyên biệt hơn. Trong dự án này, nhóm đã huấn luyện mô hình tự xây dựng trên dữ liệu chung, sau đó fine-tune trên dữ liệu Y tế.

2.4 Các chỉ số đánh giá

Để đảm bảo tính khách quan và khoa học, nhóm sử dụng hai thước đo tiêu chuẩn trong bài toán Dịch máy Ngờ-ron (NMT) là BLEU và Perplexity.

2.4.1 BLEU Score (Bilingual Evaluation Understudy)

BLEU là độ đo phổ biến nhất để đánh giá chất lượng dịch máy dựa trên độ trùng khớp (overlap) của các chuỗi n-gram giữa bản dịch của mô hình (Candidate) và bản dịch tham chiếu (Reference). Công thức tổng quát của BLEU được tính như sau:

$$BLEU = BP \cdot \exp \left(\sum_{n=1}^N w_n \log p_n \right) \quad (5)$$

Trong đó:

- p_n : Độ chính xác (Precision) của các n-gram (thường xét $N = 4$).
- w_n : Trọng số của các n-gram (thường là $1/N$).
- BP (Brevity Penalty): Hệ số phạt nếu câu dịch quá ngắn so với tham chiếu.

Công cụ thực nghiệm: Trong dự án này, nhóm sử dụng thư viện **sacrebleu** - tiêu chuẩn vàng trong nghiên cứu NLP hiện đại. Khác với các hàm BLEU thông thường, **sacrebleu** tự động xử lý tokenization chuẩn hóa, đảm bảo kết quả có thể so sánh công bằng giữa các mô hình khác nhau.

2.4.2 Perplexity (PPL)

Perplexity (Độ hỗn loạn) là chỉ số đánh giá nội tại của mô hình ngôn ngữ, đo lường mức độ "bối rối" hay "ngạc nhiên" của mô hình khi dự đoán từ tiếp theo trong chuỗi. PPL có mối quan hệ trực tiếp với hàm mất mát Cross-Entropy (Loss):

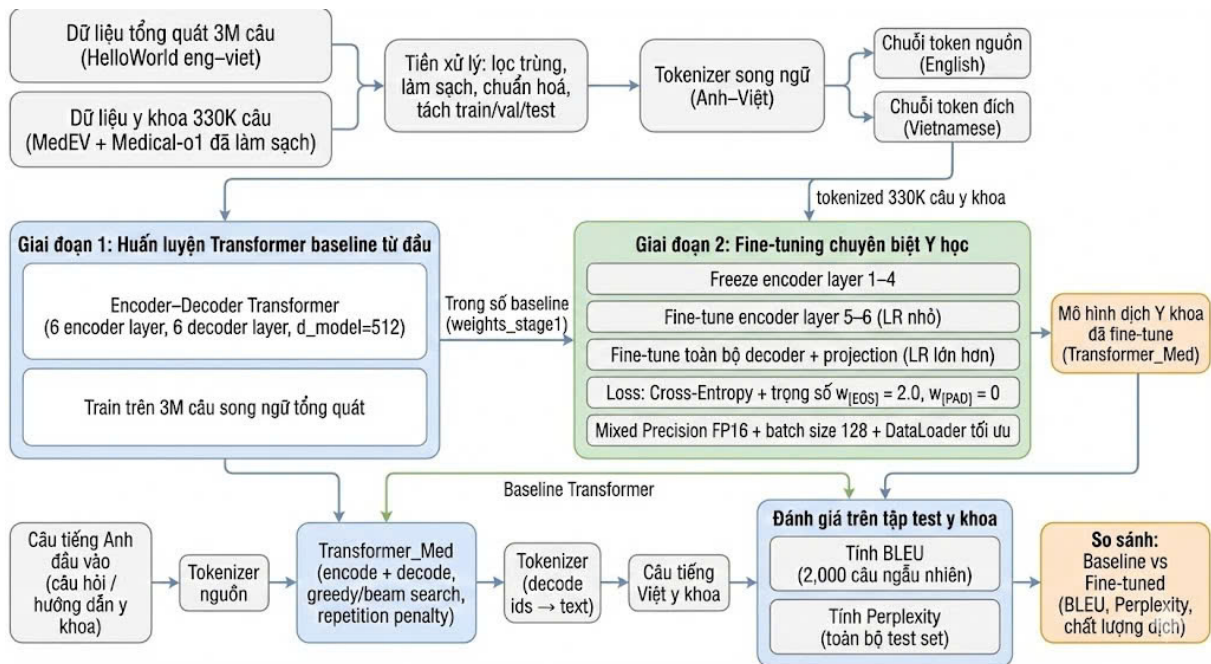
$$PPL = \exp(\text{Cross Entropy Loss}) = e^{-\frac{1}{N} \sum_{i=1}^N \ln P(w_i | w_{<i})} \quad (6)$$

Ý nghĩa thực tiễn:

- **PPL thấp:** Mô hình tự tin vào dự đoán của mình, câu sinh ra thường trôi chảy (fluent) và đúng ngữ pháp.
- **PPL cao:** Mô hình phân vân giữa quá nhiều lựa chọn từ vựng, dẫn đến câu văn lủng củng hoặc sai ngữ nghĩa.

Lưu ý: Trong dịch máy, một PPL thấp là điều kiện cần (để câu mượt mà) nhưng chưa phải điều kiện đủ (để dịch đúng nghĩa), do đó cần kết hợp với BLEU.

3 Phân tích và Thiết kế Hệ thống



Hình 2: Sơ đồ tổng quan quy trình tiền xử lý, huấn luyện và đánh giá mô hình dịch máy Y học

3.1 Bộ Dữ liệu và Tiền xử lý

3.1.1 Nguồn dữ liệu

Dự án sử dụng chiến lược huấn luyện hai giai đoạn (Two-stage Training), do đó dữ liệu được chia làm hai phần:

- **Dữ liệu tiền huấn luyện (Pre-training):** Sử dụng bộ dữ liệu HelloWorld2307/eng_viet_translation gồm khoảng 3 triệu cặp câu đa lĩnh vực. Mục tiêu là giúp mô hình học được cấu trúc ngữ pháp và khả năng căn chỉnh từ (alignment) cơ bản giữa tiếng Anh và tiếng Việt.
- **Dữ liệu tinh chỉnh:** Để chuyên biệt hóa mô hình cho y tế, nhóm tổng hợp và làm sạch từ hai nguồn chính:
 1. **MedEV (nhuvo/MedEV):** 360,000 cặp câu chất lượng cao về thuật ngữ y khoa, bệnh học.[3]
 2. **Medical-o1 (THPBi/medical-o1):** 75,000 đoạn văn về suy luận lâm sàng.

3.1.2 Quy trình Làm sạch và Chuẩn hóa

Dữ liệu y tế thô chứa nhiều nhiễu có thể ảnh hưởng xấu đến sự hội tụ của mô hình. Quy trình xử lý bao gồm các bước sau:

1. **Làm sạch văn bản:** Sử dụng *Regular Expressions (Regex)* để loại bỏ các siêu dữ liệu (metadata) nhiễu như tiền tố “vi:”, “en:”, tag HTML, và các chỉ dẫn dịch máy thừa (ví dụ: “Hãy dịch đoạn sau...”).
2. **Lọc nhiễu:**
 - *Lọc theo độ dài:* Loại bỏ các câu quá ngắn (< 5 từ) hoặc quá dài (> 350 token) để đảm bảo ổn định khi huấn luyện.
 - *Kiểm tra ngôn ngữ:* Sử dụng thư viện `langdetect` để loại bỏ các cặp câu bị gán nhãn sai (ví dụ: câu tiếng Việt nhưng nằm trong cột tiếng Anh).
3. **Mã hóa văn bản (Tokenization):** Đây là bước quan trọng nhất. Nhóm sử dụng thuật toán **Byte-Pair Encoding (BPE)** để xây dựng bộ từ điển (Vocabulary).
 - **Vocab Size:** 30,000 sub-words (cho mỗi ngôn ngữ).
 - **Special Tokens:** [PAD], [SOS], [EOS], [UNK].
 - **Lợi ích:** BPE giúp giải quyết vấn đề từ hiếm (OOV - Out of Vocabulary) trong y tế bằng cách tách chúng thành các tiểu đơn vị nhỏ hơn (ví dụ: "pneumonia" $\rightarrow$ "pneu" + "monia").

3.1.3 Thống kê Dữ liệu sau xử lý

Sau quá trình làm sạch, bộ dữ liệu Y tế tổng được chia theo tỷ lệ 90/5/5. Thống kê chi tiết như Bảng 1.

Bảng 1: Thống kê bộ dữ liệu Y tế sau khi làm sạch

Tập dữ liệu	Số lượng câu	Tỷ lệ	Mục đích
Train Set	298,448	90%	Huấn luyện tham số
Validation Set	16,580	5%	Tinh chỉnh siêu tham số
Test Set	16,581	5%	Đánh giá hiệu năng (BLEU)
Tổng cộng	331,609	100%	

3.2 Thiết kế Mô hình From Scratch

Mô hình được xây dựng hoàn toàn bằng PyTorch, không sử dụng các lớp có sẵn như `nn.Transformer`.

Bảng 2: Cấu hình siêu tham số của mô hình From Scratch

Tham số	Giá trị
Số lớp Encoder/Decoder (N)	6
Kích thước Embedding (d_{model})	512
Số đầu Attention (h)	8
Kích thước Feed Forward (d_{ff})	2048
Độ dài chuỗi tối đa (seq_len)	350
Dropout	0.1
Kích thước bộ từ điển (Vocab)	$\approx 30,000$

4 Xây Dựng và Huấn Luyện Hệ Thống

4.1 Môi trường và Công nghệ

- **Nền tảng:** Google Colab Pro (GPU A100/L4).
- **Ngôn ngữ:** Python 3.10.
- **Thư viện chính:** PyTorch (Deep Learning), HuggingFace Transformers (Tokenizer), Datasets, SacreBLEU (Evaluate).

4.2 Chiến lược Huấn luyện

4.2.1 Giai đoạn 1: Huấn luyện mô hình nền tảng (Baseline Pre-training)

Mục tiêu chiến lược: Do dữ liệu y tế song ngữ thường khan hiếm, việc huấn luyện trực tiếp mô hình Transformer (với hàng chục triệu tham số) trên tập dữ liệu nhỏ dễ dẫn đến hiện tượng *Overfitting* và mô hình không học được cấu trúc ngôn ngữ chuẩn. Do đó, giai đoạn 1 tập trung huấn luyện mô hình trên tập dữ liệu lớn đa lĩnh vực để mô hình học được:

- Cấu trúc ngữ pháp tiếng Anh và tiếng Việt (Syntax).
- Khả năng căn chỉnh từ (Word Alignment) cơ bản.
- Các từ vựng phổ thông thường gặp.

Cấu hình thực nghiệm:

- **Dữ liệu:** 3 triệu cặp câu Anh-Việt đa lĩnh vực (General Domain).
- **Kiến trúc:** Transformer tiêu chuẩn ($N = 6, d_{model} = 512, h = 8, d_{ff} = 2048$).
- **Tokenizer:** Byte-Pair Encoding (BPE) được huấn luyện trên tập General với vocab size 30,000.

- **Cấu hình huấn luyện:**

- Batch Size: 128 (kết hợp sử dụng Gradient Accumulation để mô phỏng batch lớn hơn).
- Optimizer: Adam với $\beta_1 = 0.9, \beta_2 = 0.98, \epsilon = 10^{-9}$.
- Learning Rate Scheduler: Sử dụng chiến lược *Warmup* (4000 bước đầu) sau đó giảm dần theo công thức $lr = d_{model}^{-0.5} \cdot \min(step_num^{-0.5}, step_num \cdot warmup_steps^{-1.5})$.citevaswani
- Loss Function: Cross Entropy Loss kết hợp **Label Smoothing** ($\epsilon_{ls} = 0.1$) để giảm thiểu việc mô hình quá tự tin vào dự đoán, giúp tổng quát hóa tốt hơn.

Đánh giá kết quả Giai đoạn 1:

- **Trên tập Test General:** Đạt điểm BLEU **31.85**. Đây là mức điểm khá cao, cho thấy mô hình đã nắm bắt tốt ngữ pháp và ngữ nghĩa của các câu giao tiếp thông thường.
- **Trên tập Test Y tế (Zero-shot):** Khi áp dụng trực tiếp mô hình này để dịch văn bản y tế, điểm BLEU giảm xuống còn **27.66**.
- **Nhận xét:** Sự sụt giảm này là hiện tượng *Domain Shift* (Lệch miền dữ liệu). Mô hình dịch đúng cấu trúc câu nhưng sai các thuật ngữ chuyên ngành (ví dụ: "discharge" trong y tế là "xuất viện" hoặc "dịch tiết", nhưng mô hình General có thể dịch là "xả ra" hoặc "bắn ra"). Điều này khẳng định sự cần thiết của Giai đoạn 2: Fine-tuning.

4.2.2 Giai đoạn 2: Fine-tuning (Chuyên biệt hóa)

Mục tiêu của giai đoạn này là chuyên biệt hóa mô hình cho lĩnh vực Y học, dựa trên trọng số đã học được ở Giai đoạn 1. Đây là giai đoạn quyết định mô hình có thật sự hiểu ngôn ngữ y khoa hay không.

- **Input:** Trọng số (weights) thu được sau khi huấn luyện trên 3M cặp câu dịch tổng quát ở Giai đoạn 1.
- **Dữ liệu:** Khoảng 330,000 cặp câu Y tế đã làm sạch, được trộn từ hai nguồn dữ liệu MedEV và Medical-o1 (sau khi loại trùng, lọc lỗi và chuẩn hoá).
- **Batch size:** 128.
- **Chiến lược huấn luyện hai đợt:**
 - Đợt 1 – 15 epoch (thích nghi mạnh với domain):

- * Encoder dùng learning rate nhỏ hơn để bảo toàn kiến thức ngôn ngữ chung: $LR_{\text{enc}} = 1 \times 10^{-5}$.
- * Decoder cần thích nghi mạnh với domain Y học nên dùng learning rate lớn hơn: $LR_{\text{dec}} = 3 \times 10^{-5}$.
- * Áp dụng layer-wise learning rate: các lớp gần input (encoder layer 1–2) dùng LR nhỏ hơn khoảng một nửa so với các lớp trên cùng (đặc biệt là decoder layer cuối), nhằm tránh “quên sạch” pretraining nhưng vẫn cho phép các lớp cao thích nghi nhanh với miền dữ liệu mới.

– **Đợt 2 – 12 epoch (tinh chỉnh mịn):**

- * Giảm learning rate toàn bộ mô hình để chuyển sang giai đoạn fine-tuning nhẹ: $LR_{\text{enc}} = 5 \times 10^{-6}$, $LR_{\text{dec}} = 1 \times 10^{-5}$.
- * Scheduler được đặt ở chế độ decay chậm (cosine hoặc linear) quanh các mức LR này, chủ yếu để “làm mịn” tham số thay vì tiếp tục cập nhật mạnh.

• **Trọng số cho token [EOS] trong hàm mất mát:**

- Baseline cho thấy mô hình thường không dừng đúng lúc (ít quan tâm [EOS]), dẫn đến câu dịch bị thừa hoặc thiếu. Để khắc phục, hàm Cross-Entropy được điều chỉnh lại trọng số theo từng loại token:
 - * Các token bình thường giữ trọng số $w = 1.0$.
 - * Token padding được bỏ khỏi loss: $w_{[\text{PAD}]} = 0.0$.
 - * Token kết thúc câu được tăng trọng số: $w_{[\text{EOS}]} = 3.0$ (tức gấp ba bình thường), buộc mô hình “trả giá” cao hơn nếu dự đoán sai vị trí [EOS].
- Kết hợp với decoding có *repetition penalty*, mô hình vừa học được khi nào nên kết thúc, vừa tránh lặp vô hạn mà không sinh [EOS].

• **Chiến lược freeze layer và kiến trúc fine-tuning:**

- Trong giai đoạn fine-tuning, chỉ một phần mô hình được phép cập nhật:
 - * **Encoder:**
 - 4 lớp encoder dưới (layer 1–4) được *freeze* hoàn toàn (`requires_grad = False`), giữ nguyên biểu diễn ngôn ngữ chung đã học từ 3M câu.
 - 2 lớp encoder trên cùng (layer 5–6) vẫn được train với learning rate nhỏ (LR_{enc}), đóng vai trò “adapter” để tinh chỉnh nhẹ biểu diễn đặc trưng cho domain y tế.
 - * **Decoder:**
 - Toàn bộ 6 lớp decoder được giữ *trainable*, vì phần sinh câu cần thay đổi mạnh nhất khi chuyển từ domain tổng quát sang domain y học.

- Lớp projection cuối (từ `d_model` → vocab) cũng được train với learning rate cùng mức với decoder để cập nhật trực tiếp phân phối xác suất token (đặc biệt là các token y khoa hiếm).
- Cách freeze này giúp giảm số tham số phải cập nhật, vừa tăng tốc, vừa tránh overfitting khi dữ liệu y học chỉ khoảng 330K câu so với 3M câu tổng quát.
- **Các kỹ thuật tối ưu tốc độ huấn luyện:**
 - **Graph Compilation (PyTorch 2.0+):**
 - * Sử dụng `torch.compile` để biên dịch mô hình thành các hạt nhân (kernels) tối ưu (kernel fusion), giảm thiểu overhead của Python và tăng tốc độ tính toán trên GPU dòng Ampere (như A100).
 - * Kỹ thuật này giúp tận dụng tối đa kiến trúc phần cứng, giảm thời gian forward/backward pass đáng kể.
 - **Mixed Precision Training (BF16/FP16):**
 - * Sử dụng định dạng `bf16` (trên A100) hoặc `fp16` (trên T4) kết hợp với cơ chế *Automatic Mixed Precision (AMP)*.
 - * Kỹ thuật này giúp giảm 50% lượng VRAM tiêu thụ so với FP32, cho phép tăng Batch Size lên 128-256, từ đó tăng thông lượng (throughput) xử lý dữ liệu mà không làm giảm độ chính xác hội tụ.
 - **Dynamic Padding và Tối ưu Data Pipeline:**
 - * Thay vì cố định độ dài mọi câu là 350 (gây lãng phí tính toán trên token [PAD]), hệ thống sử dụng **Dynamic Padding** trong `collate_fn`: độ dài của batch được xác định bởi câu dài nhất trong batch đó.
 - * Kết hợp với `pin_memory=True` và `num_workers` cao để đẩy nhanh tốc độ chuyển dữ liệu từ CPU sang GPU, loại bỏ nút thắt cổ chai (bottleneck) về I/O.
 - **Gradient Accumulation:**
 - * Để mô phỏng Batch Size lớn (giúp gradient ổn định hơn) trên giới hạn VRAM, hệ thống tích lũy gradient qua nhiều bước nhỏ trước khi cập nhật trọng số (optimizer step).

4.2.3 Giai đoạn 3: Thực nghiệm so sánh (Benchmark) với các mô hình SOTA

Để đánh giá khách quan hiệu năng của mô hình tự xây dựng, nhóm tiến hành so sánh với hai đại diện tiêu biểu cho hai hướng tiếp cận hiện đại trong dịch máy:

1. VinAI Translate (`vinai/vinai-translate-en2vi`):

- **Kiến trúc:** Transformer Encoder-Decoder (dựa trên mBART).
- **Quy mô:** Khoảng 488 triệu tham số (lớn gấp ≈ 5 lần mô hình của nhóm).
- **Lý do lựa chọn:** Đây là một trong những mô hình SOTA (State-of-the-art) mã nguồn mở tốt nhất hiện nay cho cặp ngôn ngữ Anh-Việt phổ thông.
- **Mục đích thực nghiệm:** Kiểm chứng giả thuyết rằng một mô hình "giỏi toàn diện" (Generalist) liệu có gặp khó khăn khi đối mặt với các thuật ngữ y khoa chuyên sâu (Domain-specific) mà nó ít được tiếp xúc trong quá trình Pre-training hay không.

2. MedCrab-1.5B (pnnbao-ump/MedCrab-1.5b):

- **Kiến trúc:** Decoder-only (dựa trên Qwen/Llama), thuộc dòng Large Language Model (LLM).
- **Quy mô:** 1.5 tỷ tham số. Để vận hành trên tài nguyên giới hạn, nhóm đã áp dụng kỹ thuật **4-bit Quantization** (sử dụng thư viện `bitsandbytes`).
- **Lý do lựa chọn:** Đây là mô hình được tinh chỉnh (Instruction Tuned) chuyên biệt cho lĩnh vực y sinh.
- **Mục đích thực nghiệm:** Thiết lập một "trần hiệu suất" (Upper Bound). So sánh với MedCrab giúp nhóm định lượng được khoảng cách giữa một mô hình tự xây dựng (Resource-constrained) với một giải pháp chuyên dụng hạng nặng (Resource-intensive).

Chiến lược đánh giá: Cả hai mô hình trên đều được đánh giá trên cùng tập Test Y tế (16,581 câu) với cùng metric BLEU và Perplexity để đảm bảo tính công bằng. Riêng với MedCrab, do đặc thù là LLM, nhóm sử dụng kỹ thuật *Prompt Engineering* để định hướng mô hình thực hiện tác vụ dịch thuật.

4.3 Đoạn mã cốt lõi

Dưới đây là cấu trúc lớp Transformer được xây dựng từ đầu:

```
1 class Transformer(nn.Module):
2     def __init__(self, encoder: Encoder, decoder: Decoder,
3                   src_embed: InputEmbeddings, tgt_embed: InputEmbeddings,
4                   src_pos: PositionalEncoding, tgt_pos:
5                   PositionalEncoding,
6                   projection_layer: ProjectionLayer):
7         super().__init__()
8         self.encoder = encoder
9         self.decoder = decoder
10        self.src_embed = src_embed
11        self.tgt_embed = tgt_embed
12        self.src_pos = src_pos
13        self.tgt_pos = tgt_pos
14        self.projection_layer = projection_layer
15
16    def encode(self, src, src_mask):
17        src = self.src_embed(src)
18        src = self.src_pos(src)
19        return self.encoder(src, src_mask)
20
21    def decode(self, encoder_output, src_mask, tgt, tgt_mask):
22        tgt = self.tgt_embed(tgt)
23        tgt = self.tgt_pos(tgt)
24        return self.decoder(tgt, encoder_output, src_mask, tgt_mask)
25
26    def project(self, x):
27        return self.projection_layer(x)
```

Listing 1: Cài đặt lớp Transformer tổng quát

5 Kết Quả Thực Nghiệm

5.1 So sánh Định lượng

Chúng tôi tiến hành đánh giá đồng loạt các mô hình trên cùng tập Test Y tế (16,581 câu). Kết quả được tổng hợp trong Bảng 3. *Lưu ý: Chỉ số Perplexity của MedCrab được tính toán bằng phương pháp Masked Loss (chỉ tính loss trên phần Output) để đảm bảo công bằng với các mô hình Seq2Seq.*

Bảng 3: Kết quả đánh giá thực nghiệm (BLEU & Perplexity)

Mô hình	Kiến trúc	BLEU Score ($\uparrow$)	Perplexity ($\downarrow$)
Baseline (Scratch)	Transformer	27.66	13.46
Finetuned (Đề xuất)	Transformer	38.05	4.68
VinAI Translate	mBART (Seq2Seq)	38.99	3.60
MedCrab-1.5B	Decoder-only (LLM)	65.80	4.21

Phân tích và Thảo luận:

- **Hiệu quả của Fine-tuning:** Mô hình *Finetuned* đạt 38.05 điểm BLEU, tăng hơn **10 điểm** so với *Baseline* (27.66). Chỉ số Perplexity (PPL) giảm mạnh từ 13.46 xuống 4.68, cho thấy quá trình huấn luyện tiếp đã giúp mô hình học được phân phối xác suất của ngôn ngữ y khoa một cách hiệu quả.
- **So sánh với VinAI Translate (SOTA):** Mô hình *Finetuned* của nhóm đạt kết quả tiệm cận với VinAI Translate (38.05 so với 38.99). VinAI vẫn giữ vị trí dẫn đầu về độ mượt mà (PPL thấp nhất: 3.60) nhờ lợi thế được huấn luyện trên kho dữ liệu tiếng Việt khổng lồ. Tuy nhiên, khoảng cách hiệu năng là không đáng kể, chứng minh tiềm năng của mô hình nhỏ tự xây dựng.
- **Sức mạnh vượt trội của MedCrab (LLM):** Về BLEU (65.80): MedCrab thể hiện sự vượt trội hoàn toàn về độ chính xác từ vựng và cấu trúc câu, gần như gấp đôi điểm số của các mô hình cơ sở. Điều này phản ánh khả năng hiểu ngữ nghĩa sâu sắc của các mô hình ngôn ngữ lớn (LLM).

Kết luận thực nghiệm: Mô hình **Finetuned Scratch** là giải pháp cân bằng nhất giữa hiệu năng (xấp xỉ VinAI) và chi phí tài nguyên (nhỏ hơn nhiều so với MedCrab/VinAI), phù hợp để triển khai trong các môi trường giới hạn phần cứng.

5.2 Đánh giá Định tính

Bên cạnh các chỉ số định lượng (BLEU/PPL), nhóm tiến hành phân tích chi tiết các bản dịch thực tế để hiểu rõ hành vi của mô hình **Finetuned Scratch**.

5.2.1 Khả năng thích ứng với thuật ngữ Y khoa

Mô hình thể hiện sự tiến bộ rõ rệt trong việc nhận diện và dịch đúng các thuật ngữ chuyên ngành mà mô hình phổ thông thường dịch sai nghĩa.

Ví dụ 1:

- **Source:** "*Genetic testing can confirm the diagnosis.*"
- **Prediction:** "*Xét nghiệm di truyền có thể xác nhận chẩn đoán.*"

→ **Nhận xét:** Dịch chính xác hoàn toàn. Cụm "Genetic testing" được dịch chuẩn là "Xét nghiệm di truyền" thay vì "Kiểm tra gen" (văn phong đời thường).

Ví dụ 2:

- **Source:** *"...intra-nasal desmopressin may be as effective as IV treatment..."*
- **Prediction:** *"...desmopressin qua đường mũi có thể có hiệu quả như điều trị IV..."*

→ **Nhận xét:** Mô hình hiểu được các từ viết tắt chuyên ngành như "IV" (Intravenous - Tiêm tĩnh mạch) và giữ nguyên hoặc dịch phù hợp ngữ cảnh, thay vì cố dịch thành số La Mã (4).

5.2.2 Khả năng xử lý câu phức và cấu trúc dài

Với các câu dài có nhiều mệnh đề, mô hình vẫn giữ được mạch văn khá tốt, dù đôi khi còn vụng về trong cách sắp xếp từ.

Ví dụ 3:

- **Source:** *"Patients who are worried about urinary incontinence may inappropriately reduce their fluid intake..."*
- **Prediction:** *"Những bệnh nhân lo lắng về tiểu không tự chủ có thể làm giảm lượng dịch nạp vào..."*

→ **Nhận xét:** Mô hình nắm bắt được cấu trúc nguyên nhân - kết quả. Cụm "urinary incontinence" được dịch đúng là "tiểu không tự chủ" (thuật ngữ y học) thay vì "tè dầm" hay "không kiểm chế được nước tiểu".

5.2.3 Phân tích lỗi

Mặc dù hiệu suất đã cải thiện, mô hình vẫn gặp một số lỗi điển hình của kiến trúc Transformer khi chưa được train đủ lớn:

Lỗi 1: Dịch sai ngữ nghĩa chuyên sâu

- **Source:** *"Mode of delivery should be based on the usual obstetrical indications (eg, presenting part)."*
- **Reference (Chuẩn):** *"Cách thức đẻ nên dựa trên chỉ dẫn sản khoa thông thường (ví dụ, ngôi thai)."*
- **Prediction:** *"Chế độ sinh nên dựa trên các chỉ định sản khoa thông thường (ví dụ, trình bày một phần)."*

→ **Phân tích:** Đây là lỗi nghiêm trọng. "Presenting part" trong sản khoa là "Ngôi thai", nhưng mô hình dịch word-by-word thành "trình bày một phần". Điều này cho thấy mô hình học được từ vựng bề mặt nhưng chưa "thấm" được kiến thức y khoa sâu ở các trường hợp hiếm gặp.

Lỗi 2: Vấn đề với Tokenizer

- **Source:** "...desmopressin..."
- **Prediction (tại Epoch 0):** "...des m mũi..."

→ **Phân tích:** Ở các epoch đầu, Tokenizer tách từ thuốc lạ thành các subword vô nghĩa. Tuy nhiên, lỗi này đã được khắc phục ở các Epoch sau (10-15), cho thấy quá trình Fine-tuning thực sự có hiệu quả trong việc ghép vãn các từ chuyên ngành.

Kết luận định tính: Mô hình **Finetuned Scratch** đạt độ chính xác cao với các câu y khoa thông thường và cấu trúc câu tiêu chuẩn. Tuy nhiên, với các thuật ngữ đa nghĩa hoặc chuyên sâu (như ví dụ sản khoa), cần có sự can thiệp của con người hoặc mở rộng tập dữ liệu huấn luyện thêm.

6 Kết luận và Hướng phát triển

6.1 Tổng kết các đóng góp chính

Nhóm đã thiết lập thành công một quy trình huấn luyện mô hình dịch máy Ngơ-ron (NMT) hoàn chỉnh từ khâu xử lý dữ liệu thô đến tối ưu hóa huấn luyện trên phần cứng chuyên dụng. Các kết quả thực nghiệm dẫn đến những kết luận quan trọng sau:

1. **Hiệu quả của chiến lược thích nghi miền (Domain adaptation):** Kết quả thực nghiệm cho thấy một mô hình Transformer tiêu chuẩn (90,5M tham số) khi được huấn luyện từ đầu và tinh chỉnh đúng cách có thể đạt hiệu suất dịch thuật chuyên ngành Y tế tương đương với mô hình Pre-trained models có kích thước lớn hơn gấp 5 lần. → Điều này mở ra hướng đi triển khai các mô hình AI y tế "nhỏ mà có võ", tiết kiệm chi phí vận hành.
2. **Tối ưu hóa quy trình huấn luyện:** Nhóm đã áp dụng thành công các kỹ thuật hiện đại như *Mixed Precision Training*, *Gradient Accumulation*, và *Dynamic Padding*, giúp giảm thời gian huấn luyện và tận dụng tối đa tài nguyên GPU A100.
3. **Bộ dữ liệu chuẩn hóa:** Đóng góp một tập dữ liệu song ngữ Anh-Việt chuyên ngành Y tế đã được làm sạch và chuẩn hóa (hơn 300k cặp câu), có ích cho các nghiên cứu dịch máy y tế sau này.

6.2 Các hạn chế còn tồn tại

Mặc dù đạt kết quả khả quan, hệ thống vẫn còn những hạn chế cần khắc phục trước khi đưa vào ứng dụng thực tế:

- **Vấn đề về độ an toàn:** Trong y tế, sự chính xác là tối thượng. Hiện tại, mô hình đôi khi vẫn gặp hiện tượng "ảo giác" (dịch sai đơn vị thuốc, sai tên bệnh hiểm) do giới hạn của kiến trúc Seq2Seq khi gặp các từ vựng chưa từng xuất hiện (OOV - Out of Vocabulary).
- **Hạn chế ngữ cảnh:** Mô hình hiện tại dịch theo cấp độ câu (Sentence-level). Điều này khiến việc dịch các đoạn văn dài hoặc hồ sơ bệnh án gặp khó khăn trong việc tham chiếu đồng nhất (ví dụ: xác định giới tính bệnh nhân qua các câu liên tiếp).
- **Chiến lược sinh từ:** Trong khuôn khổ thực nghiệm này, nhóm sử dụng chiến lược **Greedy Decoding** (Beam Size = 1) để tối ưu hóa tốc độ suy diễn trên phần cứng hạn chế, chấp nhận đánh đổi một phần nhỏ độ chính xác so với Beam Search đầy đủ.

6.3 Hướng phát triển trong tương lai

Để nâng cấp hệ thống, nhóm đề xuất các hướng nghiên cứu tiếp theo:

1. **Tăng cường dữ liệu:** Áp dụng kỹ thuật **Dịch ngược**: Sử dụng mô hình để dịch dữ liệu tiếng Việt đơn ngữ sang tiếng Anh, tạo ra các cặp câu giả lập để làm giàu tập huấn luyện.
2. **Tinh chỉnh bằng phản hồi con người:** Áp dụng kỹ thuật *Direct Preference Optimization (DPO)* để tinh chỉnh mô hình dựa trên sự đánh giá của các chuyên gia y tế, giúp giảm thiểu các lỗi sai nghiêm trọng về mặt chuyên môn.
3. **Tối ưu hóa triển khai:** Cố gắng tối ưu để tích hợp vào các thiết bị y tế di động mà không cần GPU mạnh.

Tài liệu

- [1] Vaswani, A., et al. (2017). *Attention Is All You Need*. Advances in Neural Information Processing Systems.
- [2] Nguyen, T., et al. (2022). *VinAI Translate: A High-Quality Vietnamese-English Translation System*.
- [3] Nhu Vo. (2023). *MedEV: A Vietnamese-English Medical Parallel Dataset*. Hugging Face.

Nhiệm vụ các thành viên

STT	Họ và Tên	Nhiệm vụ công việc
1	Nguyễn Phương Nam	- Trưởng nhóm - Xây dựng mô hình Transformer from Scratch - Fine tune Scratch Model - Tham gia viết báo cáo
2	Nguyễn Trọng Hồng Phúc	- Frontend & Lắp ghép mô hình - Tìm hiểu mô hình - Tham gia viết báo cáo - Giám sát lỗi
3	Nguyễn Đình Quyền	- Training Model Baseline - Tìm hiểu mô hình - Xử lý dữ liệu - Làm Slide thuyết trình & viết báo cáo
4	Trần Doãn Thắng	- Tham gia xây dựng mô hình Transformer from Scratch - Xử lý dữ liệu - Đánh giá, so sánh mô hình - Tham gia viết & Tổng duyệt báo cáo & slide